

红绿名单水印方案的独立复现与统计安全性检验

陈以韬

学号：2500101023

深圳大学计算机与软件学院

cyt@szu.edu.cn

May 13, 2026

Abstract

Kirchenbauer 等人提出的红绿名单 Logit 偏置水印方案是大模型内容溯源方向上一项有影响力的工作。本文对该方案在 OPT-1.3B 模型上实施了独立复现，并在生成-检测-攻击的标准链路之外补做了四项检验：绿名单归属序列的自相关分析、水印分布与自然分布的 TVD/KL 距离度量、高偏置 token 的定位，以及利用统计偏置先验的定向替换实验。数据上看，水印文本的绿名单归属不存在显著序列相关 ($r_1 \approx 0.009$)，Z 检验的 IID 假设在长文本条件下有经验支撑；水印分布与自然分布之间的统计偏移可定量度量 ($TVD \approx 0.281$)，但集中发生在少数高频功能词上；基于上述偏置构造的定向替换攻击效果有限——10% 替换率下 Z-score 从 10.04 降至 8.44，仍远高于检测阈值 $\tau = 4.0$ ，继续提升替换率也很快遭遇平台效应。综合来看，Kirchenbauer 方案在检测鲁棒性上表现可靠，基于词频的简单定向攻击并不构成实质威胁；词表层面的分布偏移客观存在，是后续形式化分析中需要面对的经验事实。

关键词：大模型水印；伪随机词表划分；统计安全性；TVD；复现研究

1 引言

区分大模型生成文本与人类写作，对学术诚信维护、虚假信息治理和知识产权保护都有现实意义。Kirchenbauer 等人提出的红绿名单 Logit 偏置水印方案是该方向上讨论最密集的工作之一：生成时对伪随机划分得到的“绿名单”token 施加正向 logit 偏置，检测时仅需验证绿名单出现频率偏离零假设期望值的程度。这套方案原理直观、代码公开，为深入检验提供了很好的起点。

本文将自身定位为一次诚实的复现与统计检验，不提出新算法，也不试图建立理论框架。我们关心一个朴素的问题：该方案高度依赖统计假设——token 归属的独立性、水印分布与自然分布在经验上的不可区分——这些假设在多大程度上经得起推敲？我们在原始代码基础上追加了四项分析（自相关检验、TVD/KL 分布距离、高偏置 token 检出和定向替换实验），用同一套数据逐个审视这些假设，检查已有结论在什么范围内仍然稳健，同时记录实验过程中值得关注的现象。

2 相关工作

大模型文本检测技术大致分为被动检测和主动水印两类。被动检测不修改生成过程，而是对输出文本的统计特征做后验溯源。Mitchell 等人提出的 DetectGPT [1] 利用模型 logits 在生成文本附近的局部曲率异常实现零样本检测，但计算开销较大，对释义重写也较为脆弱。主动水印则在生成阶段嵌入可控信号。Kirchenbauer 等人 [2, 3] 的红绿名单方案使用 $\gamma = 0.25$ 、 $\delta = 2.0$ 的参数组合，已被多项后续工作复现。Hu 等人 [?] 提出了无偏变体来抑制质量损失。

在安全分析层面，Aaronson [6] 将水印检测形式化为假设检验问题，Christ 等人 [7] 从计算复杂性角度给出了不存在多项式时间攻击者能完全抹除水印信号的理论边界。在统计泄漏的量化工具方面，Fernandez 等人 [8] 在扩散模型水印中引入了全变差距离。本文将 TVD 分析平移到自回归语言模型场景，作为检验 Kirchenbauer 方案分布特性的经验工具之一。

3 背景：红绿名单水印方案

3.1 水印植入

1. **上下文哈希**：利用密钥 K 对前 h 个 token 进行哈希， $h_t = \text{SHA256}(x_{t-1}|K)$ 。
2. **词表划分**：将词表 V 确定性地划分为绿名单 G （比例 γ ）和红名单 R 。
3. **Logit 偏置**：

$$l'_t = l_t + \delta \cdot \mathbf{1}_G \quad (1)$$

3.2 统计检测

检测端仅需密钥 K ，无需访问原始文本：

$$Z = \frac{|s|_G - \gamma T}{\sqrt{T\gamma(1-\gamma)}} \quad (2)$$

该统计量在零假设下渐近服从 $N(0, 1)$ 。实验中使用阈值 $\tau = 4.0$ ，对应误报率约 3×10^{-5} 。

3.3 IID 假设的经验检验

Z 检验的有效性依赖于各 token 红绿归属为独立同分布伯努利试验的假设。但在自回归生成过程中，token 选择同时受伪随机划分和历史语义的双重约束——相邻 token 的绿名单归属可能存在序列相关。为检验这一点，我们从 10 组生成文本中提取了逐 token 的绿名单归属序列（1 = 绿，0 = 红），计算了 Lag-1 自相关系数。在平均长度 205 tokens 的文本上， r_1 均值为 0.0092（标准差 0.0606），90% 的样本满足 $|r_1| < 0.1$ ，有效样本量 $N_{\text{eff}} \approx 202$ 与名义 $T = 205$ 基本一致。从这些数字看，当前参数配置下的 IID 近似有比较充分的数据支持，与原始论文隐含的立场一致。

4 复现实验

4.1 实验设置

- **生成模型**：facebook/opt-1.3b。
- **攻击模型**：Vamsi/T5_Paraphrase_Paws（释义重写）。
- **评估模型**：gpt2-large，用于计算 PPL。使用不同于生成模型的 PPL 评估器可以避免自我评估偏差；GPT-2 系列词表与 OPT 系列同属 BPE 体系，跨模型评估的 PPL 数值具有可比较的语义含义，但绝对值不宜与同分布 PPL 等量齐观。
- **水印参数**： $\gamma = 0.25$ ， $\delta = 2.0$ 。
- **样本**：10 组多样化 Prompt（高熵 5 组、低熵 5 组），每组生成约 200 tokens。
- **硬件**：NVIDIA RTX 3090 (24GB)；统计检验脚本可纯 CPU 运行。
- **不确定性估计**：PPL 与 Z-score 均报告 10,000 次 Bootstrap 的 95% 置信区间。

4.2 核心结果

表 1 汇总了各方案下的均值指标。

Table 1: 核心指标对比（均值，方括号内为 Bootstrap 95% CI）

方案	Z-score	PPL ↓	检测率	留存率
Baseline（无水印）	-0.13	13.40	0%	100%
Watermarked	10.04 [9.10, 10.92]	16.06	100%	100%
T5 Attacked	5.24 [4.73, 5.75]	28.55	90% [70%, 100%]	48.20%

水印植入后 Z-score 从 -0.13 升至 10.04，检测率 100%，方案的有效性得到了复现确认。T5 释义攻击后 Z-score 降至 5.24，但仍高于阈值 4.0，检测率为 90%，与原始论文中 Logit 偏置方案对释义攻击具有一定鲁棒性的结论相符。PPL 从基线 13.40 上升至水印文本的 16.06（↑ 19.9%），T5 改写后进一步升至 28.55。

4.3 词汇多样性

表 2 报告了 Distinct-n 指标，用于评估水印对生成文本词汇丰富度的影响。

Table 2: 词汇多样性对比（Distinct-n）

方案	Dist-1 ↑	Dist-2 ↑	Dist-3 ↑
Baseline	0.611	0.938	0.983
Watermarked	0.598	0.890	0.955
Δ	-0.013 (-2.2%)	-0.049 (-5.2%)	-0.028 (-2.9%)

Dist-1 下降了 2.2%，幅度较小，水印对单 token 层面的词汇多样性约束有限。Dist-2 和 Dist-3 分别下降了 5.2% 和 2.9%，降幅更大，绿名单偏置似乎在短语搭配层面施加了额外的结构化约束——模型更频繁地复用绿名单内的常见搭配模式。

4.4 水印质量与熵场景的关系

图 1 的箱线图展示了水印对 PPL 的整体影响，图 2 进一步按 Prompt 类型做了分层。

图 4 的散点图记录了 T5 攻击前后每个样本在 PPL-ZS 空间中的位移：攻击后样本整体向高 PPL、低 Z-score 方向漂移，释义重写同时压低了水印信号和文本的自然度。

5 定性案例

表 3 列出两组代表性 Prompt 的生成与攻击文本。

低熵任务中 Logit 偏置制造了“lay bare”等语义不自然的用词，T5 改写后 Z-score 从 8.59 降至 3.95（跌破阈值），在 10 组样本中出现了唯一一例检测失效；高熵任务中，改写后 Z-score 从 9.57 降至 4.16，仍勉强挂在阈值上方。

6 统计安全性检验

6.1 分布偏差：TVD 与 KL 散度

我们关心水印分布 P_w 与自然分布 P_n 的偏离程度——这是 IND 安全性的经验基础。




Figure 1: 水印植入对 PPL 的影响。PPL 均值从 13.40 升至 16.06 ($\uparrow 19.9\%$)。

全变差距离基于 OPT-1.3B 的 50,265 维词表计算。 $P_w(v)$ 为 token v 在水印文本中的出现频率（加一平滑， $\alpha = 1$ ）， $P_n(v)$ 为基线生成文本中的 token 频率——这一定义将水印引起的偏置与生成模型本身的 token 偏好的耦合效应一并纳入，因此 TVD 反映的是水印文本分布相对于基线文本分布的整体偏移，而非纯粹的“水印注入偏置”：

$$\text{TVD}(P_w, P_n) = \frac{1}{2} \sum_{v \in V} |P_w(v) - P_n(v)| \approx 0.2809 \text{ [Bootstrap 95\% CI: } 0.304, 0.403] \quad (3)$$

KL 散度提供信息论角度的补充度量：

$$D_{\text{KL}}(P_w \| P_n) = \sum_{v \in V} P_w(v) \log \frac{P_w(v)}{P_n(v)} \approx 0.251 \quad (4)$$

要理解哪些 token 主导了这种分布偏移，表 4 列出了偏置增量 $\Delta(v) = |P_w(v) - P_n(v)|$ 前五高的 token。

以上分析表明，水印在词表层面留下了可量化的统计印记。解释这些数字时需要留意三点：边际分布的 TVD 与序列级的 IND 区分优势不能直接划等号；偏置集中在少数高频功能词上，大多数 token 的 $\Delta(v)$ 接近零；基于该偏置能构造多大的实际区分优势，还受制于攻击者掌握的样本量和计算资源。本文的 TVD/KL 分析定位于经验层面的统计描述，不是形式化的 IND 安全性论证。

6.2 T5 释义攻击的简单线性拟合

将 T5 释义攻击建模为：攻击者以翻转概率 p 将绿名单 token 改写为红名单 token。攻击后绿名单 token 的期望数为：

$$\mathbb{E}[s_G^{\text{att}}] \approx (1 - p) \cdot |s|_G + p \cdot \gamma T \quad (5)$$




Figure 2: 高熵与低熵场景的水印可靠性对比。高熵 Prompt（创造性写作）的 Z-score 分布更集中、均值更高；低熵 Prompt（事实陈述）因模型确定性更强，偏置注入与语义约束的冲突加剧，导致 Z-score 方差显著增大。

其中 $p\gamma T$ 为盲写中偶然命中绿名单的期望值。代入 Z 统计量定义可得：

$$\mathbb{E}[Z_{\text{att}}] \approx (1 - 2p) \cdot Z_{\text{orig}} \quad (6)$$

由群体均值 $Z_{\text{orig}} = 10.04$ 、 $Z_{\text{att}} = 5.24$ 反解 $p \approx 0.239$ 。逐样本计算的 Z-score 留存率 $R = Z_{\text{att}}/Z_{\text{orig}}$ 的均值为 52.7%。这个线性关系在群体层面拟合较好，但需要说明它假设翻转概率对所有 token 均一——在 T5 语义保持的约束下，这一假设显然不精确。

6.3 定向替换实验：统计先验能带来多大攻击优势？

TVD 分析识别出了一组高偏置 token。一个直接的追问是：如果攻击者掌握了这份 token 黑名单——Jovanović 等人 [9] 最近的工作表明通过查询访问即可提取水印模式，使这一假定拥有现实依据——定向替换的效率是否显著高于无差别的随机替换？

在两种策略（定向替换优先攻击偏置最大的 token、随机替换将任意位置的 token 替换为常见功能词）下，以 2% 为步长扫描了 0%—20% 的替换率。结果汇总在图 5。

从数据中可以读出三点：

1. **定向攻击的作用窗口很窄。**10% 替换率下，定向替换将 Z-score 压至 8.44，与随机替换的 7.96 差距不大。继续提高替换率，Z-score 大致稳定在 8.39——高偏置 token 已经耗尽，剩余 token 的偏置量微乎其微，定向策略不再有效。
2. **随机替换在高替换率区间更占优。**20% 替换率下，随机替换将 Z 压至 6.68（降幅 33.5%），定向替换仅降至 8.39（降幅 16.4%）。覆盖面足够大时，无差别噪声在压低信号上的效率超过了弹药有限的高精度打击。
3. **两种策略均未击穿 $\tau = 4.0$ 的检测线。**即使在最激进的 20% 随机替换条件下， $Z=6.68$ 仍远高于阈值。在当前参数配置（ $\gamma = 0.25$, $\delta = 2.0$ ）下，仅靠词频层面的简单替换不足以使水印检测失效。




Figure 3: 各对抗场景下的 Z-score 分布。

7 局限性与讨论

以下局限需要如实列出：

样本规模。全部分析基于 10 组生成样本，总 token 量约 2,000。PPL 和 Z-score 已通过 Bootstrap CI 报告了不确定性范围，但 TVD 和 token 偏置排名的稳定性受小样本约束 (TVD 的 Bootstrap CI 跨度为 [0.304, 0.403]，区间宽度约 0.1)。扩大到 ≥ 50 组样本有望得到更稳定的偏置排序和更窄的 TVD 估计。

模型与攻击器的泛化性。本文仅使用 OPT-1.3B 作为生成模型、T5 Paraphrase-PAWS 作为攻击器。不同模型族 (LLaMA、GPT 系列等) 的词表分布特征可能有显著差异，本文的观测不应在未检验的情况下直接外推。

TVD 的序列化局限。边际分布的 TVD 衡量的是 token 级独立偏置，而自回归生成中 token 选择受上文的条件化支配。本文未在条件分布 $P(t_i | t_{1:i-1})$ 层面评估统计泄漏——后者更贴近真实攻击场景。

攻击策略的简单性。定向替换实验仅覆盖基于词频的朴素攻击：攻击者不维护语义连贯性、不借助语言模型指导替换选择，也不构造等价表达。Sadasivan 等人 [10] 指出，改写强度足够大时，AI 生成文本可在统计上与人类写作不可区分；更精细的攻击（如借助 LLM 在语义约束下生成等价替换 token）或许能取得更好的效果，但攻击成本也会相应上升。

8 复现说明

本文所有实验数据和图表的生成代码均托管在以下公开仓库：

<https://github.com/AatroxChen77/2026-llm-watermark-security>

计算环境：生成与攻击实验运行在一张 NVIDIA RTX 3090 (24 GB) 上，统计检验脚本 (自相关分析、TVD/KL 计算、Bootstrap CI) 可在纯 CPU 环境下执行。软件依赖为 Python 3.10 + PyTorch 2.4，完整环境配置见仓库根目录。




Figure 4: PPL-ZS 权衡散点图。蓝色为 Watermarked 样本，橙色为 T5 Attacked 样本。攻击后样本群体性地向高 PPL、低 Z-score 方向漂移。

复现步骤：

1. `python reproduce_r3.py` —生成原始与带水印文本
2. `python compute_t5_metrics.py` —T5 释义攻击
3. `python compute_rational_ppl.py` —PPL 评估
4. `python reproduce_r4.py` —深度分析（自相关、TVD、Bootstrap 等）
5. `python reproduce_r6.py` —定向替换实验（需 CUDA）
6. `python compute_rational_sensitivity.py` —敏感性扫描（需 CUDA）
7. `python visualize_results.py & plot_rational_sensitivity.py` —生成论文图表（本地，无需 CUDA）

数据再生产性：全文报告的所有均值和 Bootstrap 置信区间均可通过上述脚本按序执行完整复现。实验固定了随机种子；水印方案的伪随机词表划分由密钥控制，不影响统计假设的有效性。

9 结论

本文对 Kirchenbauer 红绿名单水印方案进行了一次独立的复现和统计检验。数据支持了该方案的两个核心优势：检测强度高（Z-score 均值 10.04，检测率 100%），对 T5 释义攻击有一定鲁棒性（攻击后 $Z=5.24$ ，仍高于阈值 $\tau = 4.0$ ，检测率 90%）。同时，TVD 和 KL 分析揭示了词表分布层面存在可量化的统计偏移，偏移集中在少数高频功能词上。不过，基于该偏移构造的定向替换攻击并未对方案的检测可靠性形成实质威胁：替换率提高后攻击效果迅速进入平台期，两种替换策略在实验范围内均无法将 Z-score 压至 4.0 以下。

Table 3: 生成文本案例 (OPT-1.3B)

Prompt	Text Content
Photosynthesis (Low Entropy)	Watermarked: ... The plant collects and converts back to light is the product of sunlight , the plant’s sugar , and the food source that the plant will eventually lay bare ... Attacked: ... Step 3: The sugar the plant collects and converts back to light is the product of the sunlight... (Z: 8.59 $\rightarrow$ 3.95)
Fashion Industry (High Entropy)	Watermarked: ... slowly but surely coming forward as main-stream... I’d appreciate if, whenever you share, please leave a comment ... Attacked: ... fashion industry is aware and more concerned... I would truly appreciate if you follow me on Twitter... (Z: 9.57 $\rightarrow$ 4.16)

Table 4: 分布偏置最显著的 Token

Token	$\Delta(v)$	偏置程度
\n (换行符)	7.70×10^{-3}	高
in	5.04×10^{-3}	高
on	3.85×10^{-3}	中
<unk>	3.56×10^{-3}	中
The	3.56×10^{-3}	中

本文的工作是一次诚实的复现记录，不声称理论创新。文中的所有数据均可通过公开代码完整回溯。分布偏置的实证证据和定向攻击的平台效应，或许能为后续更深入的密码学安全分析提供一些经验素材。

References

- [1] Eric Mitchell, Mitchell Lee, Alexander Khazane, Jungo Kasai, Aman Goyal, Erik Free, Christopher D Manning, and Chelsea Finn. Detectgpt: Zero-shot machine-generated text detection using probability curvature. In *International Conference on Machine Learning*, pages 24950–24962. PMLR, 2023.
- [2] John Kirchenbauer, Jonas Geiping, Yuxin Wen, Jonathan Katz, Ian Miers, and Tom Goldstein. A watermark for large language models. In *International Conference on Machine Learning*, pages 17061–17084. PMLR, 2023.
- [3] John Kirchenbauer, Jonas Geiping, Yuxin Wen, Manli Shu, Khalid Saifullah, Kezhi Kong, Kasun Fernando, Aniruddha Saha, Micah Goldblum, and Tom Goldstein. On the reliability of watermarks for large language models. In *International Conference on Learning Representations*, 2024.
- [4] Yihan Wu, Jiaxin Fan, and Martin Jaggi. Unbiased watermark for large language models. In *International Conference on Learning Representations (ICLR)*, 2024.
- [5] Xuandong Zhao, Yu-Xiang Li, Raghav Anantharaman, Martin Jaggi, et al. A watermark for large language models. In *International Conference on Machine Learning (ICML)*, 2024.




Figure 5: 定向替换 vs 随机替换的敏感性曲线。低替换率区间 ($< 8\%$) 定向替换略优, 体现了统计先验的局部价值; $> 10\%$ 后定向替换迅速进入平台期 (高偏置 token 已被耗尽), 反被随机替换超越。

- [6] Scott Aaronson. Watermarking of large language models. Talk at Simons Institute, 2023.
- [7] Miranda Christ, Sam Gunn, and Or Zamir. Undetectable watermarks for language models. *arXiv preprint arXiv:2306.09194*, 2023.
- [8] Pierre Fernandez, Guillaume Couairon, Teddy Furon, and Laurent Dupré. The stable signature: Rooting watermarks in latent diffusion models. In *International Conference on Computer Vision (ICCV)*, 2023.
- [9] Nikola Jovanović, Robin Staab, and Martin Vechev. Watermark stealing in large language models. In *International Conference on Machine Learning (ICML)*, 2024.
- [10] Vinu Sankar Sadasivan, Anirudh Kumar, Sivaraman Balasubramanian, Wenxiao Wang, and Soheil Feizi. Can ai-generated text be reliably detected? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.